

Projet Data : Challenge Enedis

Imputation de séries temporelles avec données manquantes

Seyf et Romain

Arts et Métiers Sciences et Technologies

28 janvier 2026

Le Sujet

Imputation de séries temporelles de consommation électrique comportant des données manquantes.

Le But

Comparer les performances de différentes approches : **Statistiques**, **Machine Learning**, **Deep Learning**.

Structure des données :

- Fréquence : **30 min** (48 points/jour).
- **Train** : Séries complètes.
- **Test** : Séries avec trous artificiels.

Évaluation :


- Métrique : **MAE** (Mean Absolute Error).

Typologie des Courbes de Charge



Figure – Profil type d'une courbe de consommation sur une semaine

Pipeline Méthodologique



De la donnée brute à l'évaluation du modèle.

Pipeline de Modélisation

- **1. Raw Data :**
Séries brutes de consommation électrique (fréquence 30 min).
- **2. EDA (Exploratory Data Analysis) :**
Visualisation des distributions, de la saisonnalité et des corrélations.
- **3. Preprocessing :**
Normalisation (StandardScaler) et stratégie Self-Supervised (création de masques de trous).
- **4. Feature Engineering :**
Création de variables temporelles (dates cycliques) et statistiques (moyennes glissantes).
- **5. Modèles :**
Approche progressive : Baseline KNN → XGBoost → Deep Learning.
- **6. Évaluation :**
Calcul de l'erreur absolue moyenne (MAE) par rapport à la vérité terrain.




Figure – Moyenne - Écart-type - Médiane

Analyse des Distributions :


- Moyenne (354 kW) $\gg$ Médiane (173 kW).
- **Skewness : 2.13.**

Implication

La distribution est très étalée vers la droite (quelques gros consommateurs écrasent la moyenne).

→ **Normalisation (StandardScaler)** obligatoire.

EDA 2/4 : Typologie des Données Manquantes




1. Fréquence (Haut - Bleu)

- L'immense majorité des trous sont **très petits** (1 à 2 pas de temps, soit 30-60 min).


2. Impact (Bas - Rouge)

- Les rares "grands trous" (plusieurs heures/jours) représentent un volume de données perdues massif.

EDA 3/4 : Signature Temporelle



- **Intra-day** : Profil "double bosse" (Matin/Soir) typique.
- **Semaine vs Week-end** : Conso Week-end > Semaine.
- *Insight Métier* : Cela trahit une prédominance de clients **résidentiels** (présents chez eux le week-end).



Constat :

- Corrélation moyenne très faible (**0.066**).
- Les consommateurs sont peu synchronisés.

Conséquence :

- Impossible d'utiliser des méthodes globales simples (Matrix Factorization).
- Nécessité d'aller chercher des voisins spécifiques (**KNN**) ou d'utiliser le contexte temporel (**XGBoost**).

Objectif : Transformer les séries brutes en données "apprenables".

- **Normalisation (Z-Score) :** Chaque série a son propre volume (100W vs 7000W).

$$Z_t = \frac{x_t - \mu}{\sigma}$$

Indispensable pour que le KNN compare les formes et non les amplitudes.

- **Stratégie Self-Supervised :** Création de "trous artificiels" via des masques binaires sur les données d'entraînement pour simuler la tâche finale et calculer l'erreur réelle.

Approche 1 : K-Nearest Neighbors (KNN)

Hypothèse de Similarité : "Si deux consommateurs se ressemblent sur les périodes connues, ils se ressembleront aussi sur les périodes manquantes."

Implémentation Technique :

- **Librairie** : `KNNImputer` (Scikit-learn).
- **Stratégie** : Pondération par la distance inverse ($1/d$).

Prérequis : La Normalisation

Le calcul de distance Euclidienne est sensible aux échelles !
→ Application du **Z-Score** ($z = \frac{x-\mu}{\sigma}$) obligatoire pour comparer les *formes* et non les *volumes*.

Matrice Hybride

- **Donneurs** : Séries complètes (Base de connaissance).
- **Receveurs** : Séries à trous.

Le modèle cherche les "jumeaux" numériques.

Optimisation du nombre de voisins (k)




Figure – Grid Search : Évolution de la MAE globale selon k

Zone $k < 3$

Overfitting

Sensible au bruit individuel.

Optimum $k = 4$

MAE ≈ 79.13

(Validation Interne)

Zone $k > 8$

Underfitting

Lissage excessif des pics.

Diagnostic : Performance par taille de trou




Figure – MAE moyenne en fonction de la taille du trou (pour $k = 4$)

Constat Critique :

- Le KNN est très stable sur les petits trous (barres de gauche).
- **Dégradation brutale** sur certaines séquences longues (barres hautes au centre).

Points Forts

- Excellent sur les profils "standards" et cycliques.
- Préserve la texture du signal.
- Score Baseline solide (79.13).

Limites Structurelles

- **Profils Atypiques** : Performance faible pour les industriels sans "voisins".
- **Pas d'extrapolation** : Phénomène d'écrêtage (borné par les max observés).
- **Grands Trous** : Perte de précision confirmée par l'analyse diagnostique.

→ *Nécessité d'une approche contextuelle capable de généraliser : **XGBoost**.*

Feature Engineering : Préparer le Terrain pour XGBoost

Pour transformer la série temporelle en problème de régression tabulaire :

1. Encodage Cyclique (Temps)

Les heures (0-23) sont discontinues. Pour connecter 23h à 00h, on projette sur un cercle :

$$Hour_{sin} = \sin\left(\frac{2\pi \cdot h}{24}\right)$$

$$Hour_{cos} = \cos\left(\frac{2\pi \cdot h}{24}\right)$$

2. Mémoire du Système (Lags)

Création de variables décalées pour capter l'inertie :

- **Lag 1** ($t - 30m$) : Inertie immédiate.
- **Lag 48** ($t - 24h$) : Saisonnalité jour.
- **Lag 336** ($t - 7j$) : Saisonnalité semaine.

Approche 2 : XGBoost & Imputation Itérative

Le Problème : Pour prédire y_t dans un trou, le modèle a besoin du Lag $y_{t-1} \dots$ qui est aussi manquant.

La Solution : MICE (Multivariate Imputation by Chained Equations)

- ① **Cold Start** : On remplit grossièrement les trous par Interpolation Linéaire.
- ② **Boucle Itérative** ($k = 1 \rightarrow N$) :
 - On recalcule les Features (Lags) sur les données courantes.
 - Le XGBoost prédit les nouvelles valeurs.
 - Mise à jour des trous.

L'idée : Affiner la prédiction à chaque passage.

Résultats Décevants ($MAE \approx 105 - 130$)

Pourquoi un modèle si complexe performe-t-il moins bien que le KNN ?

1. Sur-Ingénierie

- La majorité des trous sont minuscules (30 min). L'interpolation est géométriquement parfaite.
- XGBoost introduit du "bruit statistique" inutile sur ces segments simples.

2. Propagation d'Erreur

- Dans la boucle itérative, une erreur à t contamine le Lag à $t + 1$.
- Dérive progressive sur les longs trous.

La Révélation : Analyse de l'Erreur par Taille




Figure – Comparaison MAE : Interpolation (Jaune) vs KNN (Bleu) vs XGBoost (Rouge)

Constat : L'interpolation est imbattable sur le court terme, le KNN domine le long terme.

Stratégie Finale : Modèle Hybride

Le Meilleur des Deux Mondes :

- **Micro-trous** ($\leq \tau$) : Régime d'inertie physique $\rightarrow$ *Interpolation*.
- **Grands trous** ($> \tau$) : Régime structurel $\rightarrow$ *KNN*.

Optimisation du Seuil (τ) :

- Grid Search de 0 à 12 pas.
- **Optimum** : $\tau = 3$ pas (soit 1h30).




Figure – Minimisation de la MAE globale selon le seuil

Logique de Décision Déployée

Pour chaque séquence manquante $S_{missing}$:

① Calculer la longueur L (nombre de pas de 30 min).

② **SI** $L \leq 3$ (1h30) :

$$\hat{y} = \text{LinearInterpolation}(t_{start}, t_{end})$$

③ **SINON** :

$$\hat{y} = \text{KNN}(k = 4, \text{weights} = 'distance')$$

Cette hybridation agit comme un filtre de nettoyage (Denoising) sur les micro-coupures.

Score Final (MAE)

81.15

Classement : Top 25

Synthèse des Résultats :

- Le gain peut sembler modeste (quelques points), mais il est statistiquement significatif.
- **Leçon apprise** : La complexité algorithmique ne garantit pas la performance. Le respect de la physique du réseau (inertie) a prévalu.

Pourquoi XGBoost/Deep Learning ont échoué (pour l'instant) ?

- Manque de données exogènes. Avec la **Météo (Température)**, XGBoost aurait surclassé le KNN sur les pics hivernaux.
- Contraintes de temps pour le tuning de modèles lourds (SAITS/Transformers).

Feuille de route pour le Top 10 :

- 1 **Enrichissement** : Intégration API Météo-France.
- 2 **Stacking** : Remplacer le seuil dur par un méta-modèle apprenant à pondérer KNN et Interpolation.




Figure – Structure du Repository GitHub

Une approche professionnelle :

- **Code Modulaire** : Séparation claire entre src (source), conf (paramètres) et notebooks (expérimentations).
- **Open Source** : Projet documenté et accessible.
- **Reproducible** : Environnement et dépendances figés.

Positionnement sur le Leaderboard Public

20	16 mars 2025 14:10	hqad	79,6129
21	26 février 2025 21:38	awesomel	80,2614
22	13 mars 2025 23:59	sdoen	80,2934
23	9 mai 2025 09:15	SuperMath75	80,8662
24	26 novembre 2025 22:12	Antol9012	80,9125
25	27 janvier 2026 15:52	Romain-Seyf	81,1521
26	2 mars 2025 17:10	FouadLbakali	81,1930

Notre Résultat (Ligne 25)

- **Équipe** : Romain-Seyf
- **Score (MAE)** : 81.1521

Performance validée dans le Top 25, confirmant la robustesse de l'approche Hybride.

Merci de votre attention

Avez-vous des questions ?

*Projet réalisé par Seyf et Romain
Arts et Métiers*